



연구 기사

양방향 LSTM 기반 프레임워크를 이용한 레시피 제안 및 발명

사이 니컬 라오 고나¹  - 히맘수 마렐라푸디²

접수되었습니다: 2020년 11월 25일 / 수락됨 2021년 3월 31일

온라인 게시: 2021년 4월 13일

저자(들) 2021 OPEN

초록

어떤 레시피를 먹고 어떤 레시피를 피할지 선택하는 것은 누구에게나 그렇게 간단하지 않습니다. 사람들이 요리의 칼로리와 P.H 레벨을 계산하기 위해서는 많은 노력과 시간이 필요합니다. 본 논문에서는 사람의 입맛, P.H 수준, 레시피의 칼로리 함량을 기반으로 레시피를 제안하는 앙상블 신경망 구조를 제안합니다. 또한 새로운 레시피를 생성하기 위한 양방향 LSTM 기반 가변 자동 인코더를 제안합니다. 사람의 취향, 레시피의 P.H 수준, 레시피의 칼로리 함량에 따라 레시피를 분류할 수 있는 세 가지 양방향 LSTM 기반 순환신경망을 조합했습니다. 제안한 모델은 표준 손실 함수보다 더 나은 결과를 제공하는 사용자 정의 손실 함수를 제안한 레시피의 맛 등급을 예측하고 레시피의 칼로리 함량도 예측합니다. 개인에게 맞는 레시피를 학습한 후 양방향 LSTM 기반의 가변 오토인코더는 기존 레시피에서 새로운 레시피를 생성합니다. 순환신경망과 가변 자동 인코더를 학습하고 테스트한 후 20개의 새로운 레시피로 모델을 테스트한 결과, 가변 자동 인코더는 특정인에게 건강하고 특정인이 좋아할만한 새로운 레시피를 생성하는 압도적인 결과를 얻었습니다.

키워드 양방향 LSTM 기반 앙상블 신경망 - 맛, 산도 및 칼로리 예측 - 새로운 레시피 생성을 위한 양방향 LSTM 기반 변형 자동 인코더 - 레시피를 분류하는 양방향 LSTM

1 소개

좋은 음식은 건강한 삶의 가장 중요한 이유 중 하나이므로 음식은 우리가 많은 관심을 기울여야 하는 부분입니다. 이 세상에는 수많은 종류의 요리가 있지만 그 중에서도 인도 요리는 매우 특별한 위치를 차지하고 있습니다. 인도 요리의 대부분은 카레이며, 인도 전역에서 인기 있는 야채 카레 레시피는 거의 100~150가지에 달합니다. 인도에서 발견되는

음식은 의학적 가치가 높으며 단백질과 비타민이 풍부하게 함유되어 있습니다[1]. 인도에는 약 30 ~ 50 가지의 다양한 재료가 함께 추가됩니다.



것이 정말 중요합니다. 인도에서는 대부분의 사람들이 위산과다 또는 위산 역류[2]로 인해 좋아하는

을 통합하는 새로운 알고리즘이 설계되고 있습니다. MIT 연구팀과 다른 여러 연구자들은 다음과 같이 연구했습니다.

Sai Nikhil Rao Gona, gonasainikhil@gmail.com; Himamsu Marellapudi, himamsu12@gmail.com |¹ 인도 하이데라바드 차이타냐 바라티 공과대학교 전기 및 전자공학부. ²전기 및 통신 공학, 차이타냐 바라티 공과대학교 인도 하이데라바드 공과대학.



SN 응용 과학 (2021) 3:553 | <https://doi.org/10.1007/s42452-021-04548-x>

SN Applied Sciences
A **SPRINGER NATURE** journal

는 레시피의 사진을 사용하여 레시피의 재료를 예측하는 알고리즘을 설계했습니다[3, 4]. 이제 우리는 특정 건강 문제가 있는 특정 사람에게 해당 레시피가 건강한지 아닌지, 그리고 그가 레시피의 맛을 좋아할지 아닌지를 알아야 하는데, 이를 위해 가장 좋은 방법은 인공 신경망을 사용하여 맛과 건강성을 예측하는 것입니다. 인공 신경망을 사용하여 맥주 맛의 품질을 예측하는 모델이 제안되어 작업을 진행할 수 있는 지식을 얻었습니다 [5]. 우리는 맛과 건강을 통합하여 사람들이 건강하고 맛있는 레시피를 쉽게 요리 할 수 있도록하고 싶었고,이를 위해 인공 신경망을 사용하여 레시피의 맛과 건강성을 예측하기 위해 비선형 방정식을 다루기 때문에 예측된 값만 있으면됩니다. 맛을 예측하기 위해서는 사용자가 레시피를 좋아했는지 싫어했는지 미리 파악해야 하고, 건강성을 예측하기 위해서는 레시피가 산성인지 염기성인지, 고칼로리인지 저칼로리인지 예측해야 합니다. 요리가 완벽한지 아닌지를 알기 위해서는 소비자의 피드백을 받아야 합니다. 피드백은 리뷰나 단순한 '좋아요' 또는 '싫어요', 평점일 수 있습니다. 소비자가 레시피를 좋아하거나 싫어하는지, 레시피가 산성인지 아닌지, 저칼로리 레시피를 원하는지 아닌지를 말하는 것이 더 쉬운 것입니다. 이 경우 맛에 따라 호불호, 산성 또는 기본 레시피, 고칼로리 레시피 또는 저칼로리 레시피를 예측해야 하므로 출력은 0초와 1초로 간주되어 완벽한 분류 문제가 됩니다. 그래서 다양한 레시피에 대한 소비자들의 피드백을 수집했고, 레시피의 맛 등급과 칼로리만 필요한 경우를 대비해 사람들의 맛 등급과 모든 요리의 칼로리도 기록했습니다. 요리가 산성인지 염기성인지만 예측하면 되기 때문에 요리의 산도 값은 기록할 필요가 없습니다. 사람의 심리는 사람마다 다르기 때문에 음식에 대한 취향도 다르기 때문에 맛을 예측하기 위해 입력은 레시피의 재료이고 출력 값은 평점의 평균 또는 여러 사람이 제공한 0초와 1초의 호불호 평균인 데이터를 사용하여 평균이 0.5보다 크면 1로, 0보다 작으면 0으로 간주할 수 있습니다.5를 0으로 간주하거나, 입력이 레시피의 재료이고 출력이 평점인 데이터 또는 출력이 개인이 부여한 0초와 1초의 좋아요 또는 싫어요인 데이터를

사용할 수 있습니다. 이 실험을 수행하기 위해 개인이 부여한 데이터를 사용했으며 논문에서 제안할 모델은 개인이 부여한 데이터와 다수의 소비자가 부여한 평점의 평균 또는 다수의 소비자가 부여한 0초와 1초의 좋아요 또는 싫어요의 평균인 데이터 세트 모두에 사용할 수 있습니다. 다음에서 데이터를 수집한 후

데이터를 사전 처리한 다음 [6], 음식에 인공 신경망을 사용하여 요리사가 일을 더 쉽게 하고 사람들이 무엇을 먹고 무엇을 먹지 말아야 하는지 알 수 있도록 돕는다는 아이디어로 알고리즘을 설계했습니다.

이 논문에서는 건강한 사람이나 정상인, 신맛으로 고통받는 사람, 체중 감량을 원하는 사람이 좋아할만한 레시피를 준비하거나 제안하는 데 매우 유용할 수 있는 두 가지 방법론을 제안합니다. 이는 식품 산업에서 획기적인 기술이 될 수 있으며 요리사가 거의 결함이 없는 레시피를 준비하는 데 도움이 될 수 있으므로 요리가 특정 사람에게 적합한 지 여부를 예측하고 새로운 레시피를 만들기 위해 최종 출력단에 매우 간단한 게이팅 시스템과 로직 게이트를 갖춘 양방향 [7] LSTM 기반 신경망 앙상블을 설계하고 주어진 레시피의 맛이나 재료를 변경하여 새로운 레시피를 만들 수 있는 생성 모델로 양방향 LSTM 기반 변형 자동 인코더를 사용했습니다. 양방향 LSTM 기반 신경망 앙상블을 구축한 후, 무작위 사람들이 기록한 20개의 새로운 레시피에 이 모델을 사용했으며, 이 모델은 해당 레시피에서 매우 훌륭하게 작동했습니다. 이 모델은 그 사람이 요리를 좋아할지 아닌지, 건강에 좋은지 아닌지를 예측하는 데 사용되며 양방향 LSTM 기반 가변 자동 인코더와 함께 새로운 레시피를 발명하는 데에도 사용할 수 있습니다. 몇 가지 유사한 이전의 앙상블 신경망 모델 중 두 가지를 [8, 9]에서 볼 수 있습니다.

이 알고리즘은 전 세계 모든 지역의 레시피에 적용될 수 있으며, 필요한 것은 레시피 데이터와 소비자의 의견뿐입니다. 이 알고리즘은 매우 유연하여 앙상블 네트워크에 필요한 만큼의 훈련된 양방향 LSTM 기반 순환신경망을 추가하여 다양한 레시피를 만들고 모든 종류의 건강 문제가 있는 사람들에게 레시피를 제안하는 데 사용할 수 있습니다. 이 논문은 다음과 같이 구성됩니다.

- 제안된 방법론
- 데이터 및 데이터 전처리
- 실험 결과
- 결론

2 관련 작품

현재 문헌에서 칼로리 예측과 음식에 대한 딥러닝의 적용에 대한 몇 가지 연구를 찾을 수 있습니다. [10]에서 저자들은 식품의 이미지를 행렬로 변환하고 그 행렬을 '식품 유형 분류기 모델'과 '크기 예측 모델'에 입력한 후, 식품의 이미지를 통해 주어진 식품의 칼로리 함량을 예측할 수 있는 방법론을 제안했습니다.

매트릭스를 압축합니다. 11]에서 저자는 음식 추천에 대해 가장 많이 인용된 선행 연구를 모두 설명했는데, 여기에서는 레시피 재료를 입력값으로 사용하여 KNN, Naive Bayes, 랜덤 포레스트, SVM 및 로지스틱 회귀와 같은 기본 머신러닝 모델을 사용하여 등급을 예측한 선행 연구[12-17]를 찾을 수 있습니다. 18]에서 저자는 음식 이미지에서 칼로리를 예측하기 위해 심층 신경 네트워크를 사용했습니다. 19]에서 저자는 음식의 칼로리 함량과 음식의 품질을 추정하는 데 딥러닝을 어떻게 사용할 수 있는지 설명합니다. 이전 모델의 문제점은 충분히 정확하지 않다는 것입니다. 맛 등급을 예측하는 동안 모든 재료 간의 관계가 있어야 하며, 이는 양방향 LSTM을 사용하여 활성화할 수 있습니다. 칼로리를 예측할 때, 레시피의 칼로리는 조리 시간과 재료의 조합에 따라 크게 달라지기 때문에 이미지는 레시피에 대한 완전한 정보를 제공할 수 없습니다. 특정 레시피의 정확한 칼로리 함량은 사용된 모든 재료의 칼로리 함량을 단순히 합산해서는 알 수 없습니다. 따라서 우리는 이 문제를 해결할 수 있는 양방향 LSTM 기반 프레임워크의 앙상블을 사용합니다. 20]에서 저자는 문맥 정보를 양방향으로 유지할 수 있기 때문에 단어 분할에 양방향 LSTM을 사용합니다. 21]에서 저자는 확산 저수지에서 파쇄된 수평 유정의 생산을 추론하기 위해 LSTM 기반 모델을 제안하며, 이는 기존 모델에 비해 매우 정확한 예측을 보여줍니다. LSTM 신경망은 유정 시간 순서 데이터의 종속성을 포착하고 생산 제약 조건을 통합할 수 있습니다. 입자 군집 최적화 알고리즘은 LSTM 모델을 최적화하는 데 사용되었습니다. 22]에서 저자는 합성곱 신경망(CNN)과 장단기 기억망(LSTM)의 두 가지 신경망을 융합한 순차적 모델 기반의 하이브리드 궤적 예측 방법을 제안합니다. 주변 차량의 궤적은 CNN의 공간 확장 특성과 LSTM의 시간 확장 특성을 합쳐서 예측합니다. 앙상블 학습은 여러 예측 문제를 처리할 때 매우 효과적이며, 주어진 입력 특징 집합에서 결과 출력을 형성하기 위해 수학적으로 결합됩니다. 23]에서 저자들은 이미지 기반 및 컴퓨터 지원 음식 인식 작업을 위해 미세 조정 및 앙상블 학습과 함께 ResNet, GoogleNet,

VGGNet 및 InceptionV3를 사용하여 효과적인 예측을 위해 'n'개의 CNN을 사용했습니다. 24]에서는 먼저 8개의 이식형 리튬 이온 셀의 일일 순환 데이터를 소스 데이터 세트로 사용하여 8개의 심층 컨볼루션 신경망 모델을 사전 훈련했습니다. 그런 다음 사전 학습된 DCNN 모델의 학습된 파라미터를 소스 작업에서 대상 작업으로 전송하여 8개의 전이 학습이 포함된 DCNN(DCNN-TL) 모델을 생성한 다음, 이를 통합하여 앙상블 학습이 포함된 앙상블 모델인 DCNN을 구축합니다.

및 전이 학습(DCNN-ETL). 이 모델에서는 n 개의 개별 DCNN-TL 모델의 출력이 완전히 연결된 앙상블 레이어에 의해 수신되었습니다. 이 레이어는 모델 가중치를 할당하고 입력 샘플에 대한 예상 타깃을 계산하는 데 사용되었습니다.

3 제안된 방법론

3.1 맛과 건강도 예측을 위한 아키텍처 제안

신경망의 선택은 레시피 제안을 위한 논리 게이트가 있는 양방향 LSTM 기반 신경망 아키텍처의 앙상블입니다[25]. 특정 레시피 재료의 양은 여러 사람 또는 특정 개인에게 맛있고 건강한 레시피를 만드는 데 필요한 특정 레시피 재료의 양은 이전에 추가한 재료의 양과 다음에 추가할 재료의 양에 따라 크게 달라지기 때문에 레시피 제안 모델을 보여주는 그림 1과 같이 양방향 LSTM을 사용했습니다. 여러 종류의 LSTM과 서열 모델 중 양방향 LSTM을 사용한 이유는 일련의 재료들 간의 관계를 양방향으로 파악할 수 있고, 최적의 훈련 가능한 파라미터 수를 가지고 있어 H-LSTM[26], GRU[27]와 같은 다른 LSTM 및 서열 모델과 달리 합리적인 훈련 시간으로 좋은 성능을 낼 수 있기 때문입니다. 그림 1의 각 양방향 신경망은 음식의 특정 측면을 분류합니다. 우리가 관심 있는 측면은 음식의 등급, 당뇨병, 궤양, 고혈압에 대한 음식의 건강성입니다. 당뇨병 환자는 저칼로리 레시피를, 궤양 환자는 기본 레시피(산성이 아닌)를, 고혈압 환자는 저칼로리 레시피와 기본 레시피를 먹어야 합니다. 이브 리온은 나열된 건강 상태를 알고 있지 않기 때문에 신경망의 출력이 게이팅 시스템과 논리 게이트를 통과하는 게이팅 시스템과 논리 게이트를 통해 개인이 자신의 건강 상태를 선택할 수 있는 방법을 제공했습니다. 양방향 LSTM-

RNN 학습자 1은 맛에 대한 이진 출력을 원할 때는 분류기 모델이 되고, 맛 등급을 원할 때는 회귀 모델이 됩니다. 양방향 LSTM-RNN 학습자 2는 레시피의 산도에 따라 레시피를 분류하는 분류기 역할을 합니다. 양방향 LSTM-RNN 학습자 3은 레시피를 고칼로리 및 저칼로리 구성 레시피로 분류하고자 할 때 분류기 모델이 되고, 레시피의 칼로리 함량을 예측하고자 할 때는 회귀 모델이 됩니다. 양방향 LSTM-RNN 학습자가 분류기인 경우 3개의 이진 변환기 모두에 임계값 0.5를 설정하고, 양방향 LSTM-RNN 학습자 1과 양방향 LSTM-RNN 학습자 3이 회귀 모델인 경우 이진 변환기 1과 이진 변환기 3에 원하는 대로 임계값과 칼로리 값을 설정해야 합니다,

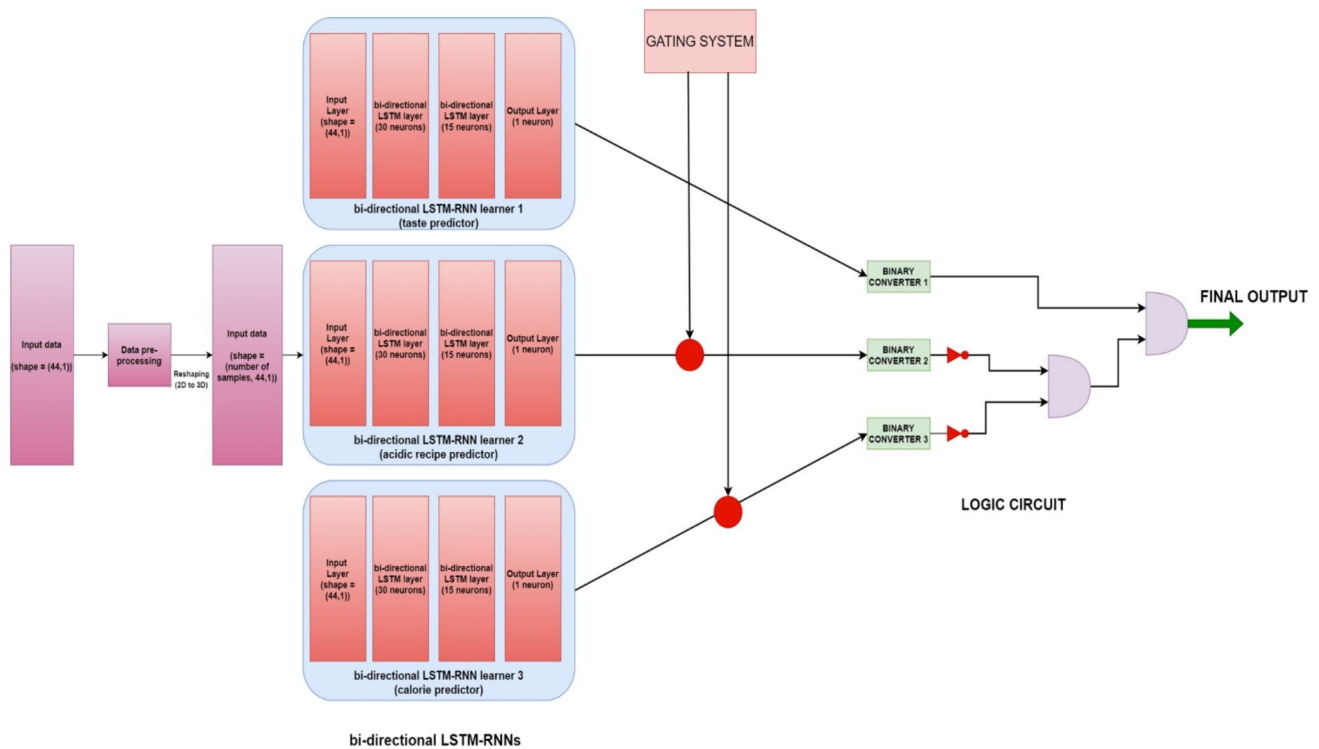


그림 1 양방향 LSTM 기반 신경망의 양상블

로 각각 표시되며, 그 이상의 레시피는 '좋아요' 레시피와 '고 칼로리' 레시피로 간주할 수 있습니다. 양방향 LSTM-RNN 학습자 3을 다음과 같은 회귀 모델로 사용하는 것은 무의미합니다.

요리가 산성인지 염기성인지 분류하기 만하면되므로 레시피의 산도를 예측하면 다음과 같은 분류기로 사용합니다. 0.5 이상의 값을 예측할 때 레시피가 고려됩니다.

를 산성으로 바꾸거나 그 반대의 경우도 마찬가지입니다. 그림 1은 제안된 양방향 LSTM 기반 신경망 양상블의 아키텍처를 보여줍니다. 신경망의 입력 레이어는 (44,1)의 모양을 가지며, 이는 3.1에서 데이터 세트에 대해 설명합니다.

양방향 LSTM-RNN은 순차적 데이터가 포함된 분류 문제에서 모델 성능을 향상시킬 수 있는 기존 LSTM의 확장입니다. 여기서는

문제, 데이터 세트의 성분은 순차적이며 추가해야 하는 각 성분의 양이 정해져 있습니다.

는 이전 성분과 다음 성분의 양에 따라 크게 달라집니다. 양

$$h_t^{(l)} = f(W_{xh}^{(l)} + W_{hh}^{(l)} * h_{t+1}^{(l)} + b_h^{(l)}) \quad (2)$$

$$y_t = W_{hy} * h_t + W_{by} * b_y \quad (3)$$

방정식 (1), (2), (3)에서

l 는 숨겨진 레이어 번호, f 는 숨겨진 레이어 함수, h_t 는 순방향 숨겨진 시퀀스, h_{t+1} 는 백워드 숨겨진 시퀀스, W_{xh} 는 입력-숨겨진 가중치입니다.

행렬, 숨겨진-숨겨진 가중치 행렬, 숨겨진-출력 가중치 행렬, 숨겨진 계층의 바이어스, 출력 계층의 바이어스인 b_h , 출력 계층의 바이어스인 b_y 에 대해 설명합니다.

표준 신경망의 출력(출력 레이어)는 다음과 같이 계산됩니다.

$$\hat{y} = \sigma(W^T X + b) \quad (4)$$

방향 LSTM을 사용하여 역은닉 시퀀스, 순은닉 시퀀스, 출력 시퀀스

평균 제곱 오차를 계산합니다. 방정식 (1), (2)을 사용하여 순방향 및 역방향 숨겨진 시퀀스, 순방향 숨겨진 시퀀스, 출력 시퀀스의 방향, x 는 입력 데이터, b 는 신경망의 바이어스입니다. 정식입니다.

3.1.1 맛 예측

그림 1에서 양방향 LSTM-RNN 학습자 1은 신경

$$\vec{h}_{ht}^{(i)} = f(W_{xh} \vec{x} + W_{hh} \vec{h}_{t-1} + b_h)$$

- (1) 네트워크는 사용자의 취향에 따라 레시피를 좋아하는 레시피와 싫어하는 레시피로 분류하고 사용자의 취향에 따라 레시피를 평가하기도 합니다. 분류를 위해

맛에 기반한 레시피를 제공하는 이 신경망은 다음과 같이 훈련됩니다.

데이터 세트의 특징으로 레시피의 재료로 구성된 데이터와 출력 레이블로 0초와 1초를 사용합니다.

를 데이터 세트에 추가합니다. 모델의 가중치는 훈련 후에 저장됩니다. 출력 레이블 열의 1은 해당 레 시 피 가 사용 자가 좋아하는 레시피임을 의미하며, 0은 해당 레시피가 사용자가 싫어하는 레시피임을 의미합니다.

양방향 LSTM-RNN 학습자 1의 0.5는 사용자가 레시피에 '좋아요'를 누른다는 의미입니다. 양방향 LSTM-RNN 학습자 1의 출력이 0.5보다 작으면 해당 레시피가 마음에 들지 않음을 의미합니다. 레시피의 맛 등급을 예측하기 위해 양방향 LSTM-RNN은 레시피의 재료를 데이터 세트의 입력 특징으로, 레시피의 등급을 출력 레이블로 구성한 데이터로 학습하고 학습 후 모델의 가중치를 저장합니다. 평점을 예측할 때 주어진 출력은 레시피의 평점이 됩니다. '좋아요 레시피'는 맛을 고려했을 때 사용자가 좋아할 만한 레시피를, '싫어요 레시피'는 사용자가 좋아하지 않을 만한 레시피를 의미합니다.

맛에 따라 레시피를 분류하는 신경망은 양방향 LSTM-RNN 학습자 1을 분류기로 사용하기 때문에 손실 함수로 '이진 교차 엔트로피'[28]를, 입력층과 숨겨진 층에는 'ReLU'[29, 30] 활성화 함수를, 출력층에는 '시그모이드' 활성화 함수[31]를 사용합니다. 레시피의 등급을 예측하는 동안 신경망은 '평균 제곱 오차' 또는 '평균 절대 오차'[32] 또는 이 애플리케이션을 위해 설계한 맞춤형 손실 함수를 손실 함수로 사용하고 입력 레이어, 숨겨진 레이어 및 출력 레이어에 대한 'ReLU' 활성화 함수를 사용할 수 있습니다. 이 신경망을 컴파일하는 동안 신경망의 가중치를 조정하기 위한 최적화 함수로 'Adam'을 사용했습니다.

이진 교차 엔트로피 손실 함수는 다음과 같이 주어집니다.

$$L_{\text{기원전}} = - \frac{1}{N} \sum_{i=1}^N \left(y_i * \log \hat{y}_i + (1 - y_i) * \log (1 - \hat{y}_i) \right) \quad (5)$$

'평균 제곱 오차' 손실 함수, '평균 절대 오차' 손실 함수 및

$$LCUSTOM = \frac{1}{N} \sum_{i=1}^N \frac{|y_i - \hat{y}_i|}{\bar{y}} * 100 \quad (8)$$

여기서 (1) 및 (2)에서,

N = 샘플의 크기입니다.

y_i = 실제 값입니다.

\hat{y}_i = 예측 값.

\bar{y} = 'N' 실제(참) 값의 평균입니다.

우리는 '평균 절대 백분율 오차'[33, 34]와 유사한 사용자 지정 손실 함수를 사용했습니다. 여기서는 예측값과 실제값의 차이인 y_i 와 \hat{y}_i 를 각각 실제값의 평균인 \bar{y} 로 나눈 다음 여기에 100을 곱하여 백분율 오차로 만듭니다. 사람마다 평점이 다르기 때문에 어떤 사람은 데이터에서 실제 값의 평균이 7인 것처럼 평점을 주고 다른 사람은 데이터에서 실제 값의 평균이 5인 것처럼 평점을 줄 수 있고, 한 그룹의 평점의 평균인 평점을 예측할 때 평균은 어떤 것이든 될 수 있으므로 y 값에 대한 오차를 구해야 하므로 y_i 와 \hat{y}_i 의 차이를 y 로 나눈 것입니다. y 의 값이 낮을 때(약 5 또는 6), 특정 값에 대해 계산된 손실 값은 y 의 값이 높을 때(약 8 또는 9) 동일한 값에 대해 얻은 손실 값보다 높을 것입니다. y 값이 낮다면 그 사람은 데이터 세트의 많은 레시피에 대해 좋은 평가를 내렸기 때문에 맛에 대해 매우 구체적이라는 의미이며, 그 결과 \bar{y} 값이 낮습니다. 사람이 구체적이기 때문에 미리 지시된 값이 실제 값에서 조금만 벗어나도 계산되는 손실 값은 y 가 낮을 때 더 커야 하고, 사람이 음식을 선택하는 데 구체적이지 않은 경우 y 가 높을 때 계산되는 손실은 y 가 낮을 때 계산되는 손실보다 작아집니다. 'ReLU' 및 '시그모이드' 활성화 기능이 제공됩니다.

as-

이 애플리케이션

을 위해 설계

N

$$l_{MSE} = \frac{1}{N} \sum_{i=1}^N (\hat{y}_i - y_i)^2$$

(6)

$$f(x) = \frac{1}{1 + e^{-x}} \quad (10)$$

는 신경망의 이전 레이어에서 계산한 값입니다.

방정식 (11)은 Adam [35] 옵티마이저를 사용하여 가중치를 업데이트하는 방법을 보여줍니다.

(7)

$$L_{MAE} = \frac{1}{N} \sum_{i=1}^N |\hat{y}_i - y_i|$$

$$w^{t+1} \leftarrow w^t - \eta * \frac{\sqrt{m_t}}{\sqrt{v_t} + \epsilon} \quad (11)$$

여기서 w^{t+1} 와 w^t 는 업데이트 전 가중치와 가중치, η 는 학습률, m_t 와 v_t 는 업데이트된 가중치입니다.

편향된 첫 번째 순간 추정치 및 업데이트된 편향된 두 번째 원시 순간 추정치. 는 작은 스칼라로, 0으로 나누지 않도록 하는 데 사용됩니다.

3.1.2 산성 레시피 예측

그림 2에서 양방향 LSTM-RNN 학습자 2는 레시피의 산도가 레시피를 만드는 데 필요한 재료의 산도와 같지 않기 때문에 레시피의 산도 함량을 기준으로 레시피를 분류하는 인공 신경망입니다. 레시피의 산도 함량을 기준으로 레시피를 분류하기 위해 이 신경망은 레시피의 성분을 데이터 세트의 특징

으로, 0초와 1초를 데이터 세트의 출력 레이블로 구성된 데이터로 학습합니다. 출력값이 1이면 레시피가 산성이고 0이면 레시피가 산성이 아님을 의미하며, 양방향 LSTM-RNN 학습자 2의 출력값이 0.5보다 크면 레시피가 산성이라는 뜻입니다. 양방향 LSTM-RNN 학습자 2의 출력이 0.5보다 작으면 레시피가 산성이 아님을 의미합니다. 이 신경망은 산성 함량에 따라 레시피를 분류할 때 양방향 LSTM-RNN을 사용하기 때문에 손실 함수로 '이진 교차 엔트로피'를 사용하고, 입력과 숨겨진 레이어에는 'RELU' 활성화 함수를, 출력 레이어에는 '시그모이드' 활성화 함수를 사용합니다. 이 신경망은 또한 'Adam'을 다음과 같이 사용합니다.

가중치 조정을 위한 최적화 기능입니다.

'이진 교차 엔트로피' 손실 함수, 'RELU' 활성화 함수 및 '시그모이드' 활성화 함수는 각각 (1), (5) 및 (6)에 나와 있습니다.

3.1.3 칼로리 예측

그림 3에서 양방향 LSTM-RNN 리너 3은 레시피의 칼로리 함량을 기반으로 레시피를 분류하고 레시피의 칼로리 수를 예측하는 인공 신경망으로, 레시피가 조리되기 때문에 레시피의 칼로리 함량은 레시피를 만드는 데 필요한 재료의 칼로리 합과 동일하지 않습니다. 칼로리를 기준으로 레시피를 분류하려면 다음과 같이 하세요.




그림 3 레시피의 실제 맛 평가

콘텐츠의 경우, 이 신경망은 레시피의 성분을 데이터 세트의 특징으로, 0초와 1초를 데이터 세트의 출력 레이블로 구성된 데이터로 학습합니다. 출력값이 1이면 레시피의 칼로리 함량이 높고 출력값이 0이면 레시피의 칼로리 함량이 보통 또는 낮음을 의미하며, ANN 학습자 3의 출력값이 0.5보다 크면 레시피의 칼로리 함량이 높다는 의미입니다. 양방향 LSTM-RNN 학습기(3)의 출력이 0.5보다 작으면 레시피의 칼로리가 보통이거나 낮다는 뜻입니다. 레시피의 칼로리 함량을 예측하기 위해 레시피의 성분을 데이터셋의 입력 특징으로, 레시피의 칼로리를 데이터셋의 출력 레이블로 구성한 데이터로 신경망을 학습시키고, 레시피의 칼로리를 예측할 때 출력은 레시피의 칼로리 함량으로 주어집니다.

칼로리 함량을 기준으로 레시피를 분류하는 이 신경망은 양방향 LSTM-RNN 학습자 3을 분류기로 사용하기 때문에 손실 함수로 '이진 교차 엔트로피'를, 입력 레이어와 숨겨진 레이어에는 'RELU' 활성화 함수를, 출력 레이어에는 '시그모이드' 활성화 함수를 사용합니다. 레시피의 칼로리를 예측하는 신경망은 손실 함수로 '평균 제곱 오차' 또는 '평균 절대 오차'를 가질 수 있으며, 'RELU'

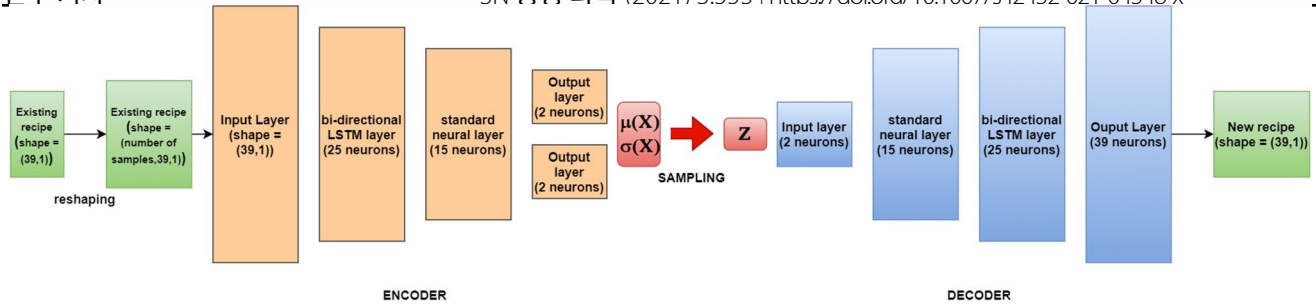


그림 2 양방향 LSTM 기반 VAE

입력 레이어, 숨겨진 레이어 및 출력 레이어에 대한 활성화 함수입니다. 이 신경망을 컴파일하는 동안 신경망의 가중치를 조정하는 최적화 함수로 'Adam'을 사용합니다.

'이진 교차 엔트로피' 손실 함수, '평균 제곱 오차' 손실 함수, '평균 절대 오차' 손실 함수, 'RELU' 활성화 함수 및 '시그모이드' 활성화 함수는 각각 (1), (2), (3), (5) 및 (6)에 나와 있습니다.

3.1.4 게이팅 시스템

그림 1의 아키텍처에 사용된 게이팅 시스템은 간단한 게이팅 시스템입니다. 1은 레시피의 산도에 신경 쓰지 않을 때 양방향 LSTM-RNN 학습자 2의 출력에 연결된 분기에서 출력 0을 주어 양방향 LSTM-RNN 학습자 2의 연결을 끊는 간단한 게이팅 시스템입니다. 레시피의 칼로리 함량에 신경 쓰지 않을 때 양방향 LSTM-RNN 학습자 3의 출력에 연결된 분기에서 0을 출력하여 양방향 LSTM-RNN 학습자 3의 연결을 끊습니다.

3.1.5 논리 회로

기본 논리 회로[36]를 사용하여 신경망의 앙상블에서 레시피를 요리할지 여부를 제안하는 최종 출력을 얻었습니다. 음식의 칼로리 섭취량과 산도에 대한 제한이 없는 일반인의 경우 게이팅 시스템의 출력은 모두 0입니다. 모델에서 가능한 결과는 0과 다음과 같은 두 가지가 있습니다.

1. 양방향 LSTM-RNN 학습기 1의 출력이 0일 때 최종 출력은 0이 되고, 양방향 LSTM-RNN 학습기 1의 출력이 1일 때 최종 출력은 1이 됩니다. 레시피의 산 함량에 제한이 있는 경우, 양방향 LSTM-RNN 학습자 2에 연결된 게이팅 시스템의 출력은 1이 되고, 양방향 LSTM-RNN 런너 3에 연결된 게이팅 시스템의 출력은 0이 됩니다. 레시피의 칼로리 함량에 제한이 있는 경우 양방향 LSTM-RNN 학습자 3에 연결된 게이팅 시스템의 출력은 1이 되고 다른 출력은 다음과 같습니다.
0. 사용자가 레시피의 산도와 칼로리 함량에 모두 제한이 있는 경우, 게이팅 시스템의 출력은 모두 1이 됩니다. 사용자

는 레시피의 산도, 레시피의 맛, 레시피의 칼로리 함량 측면에서 기대하는 요리의 종류를 레시피의 재료에서 언급하기만 하면 됩니다. 모든 경우를 고려하여 아래에 주어진 출력 방정식으로 기본 논리 회로를 설계했습니다.

여기서 G 최종 출력이고 이진 입력 1 블록을 통과한 후 양방향 LSTM-RNN 학습자 1의 출력이며 b 는 이진 입력 2 블록을 통과한 후 양방향 LSTM-RNN 학습자 2의 출력이고, c 는 이진 입력 3 블록을 통과한 후 양방향 LSTM-RNN 학습자 3의 출력입니다. 이 회로는 $a = 1, b = 0, c = 0$ 의 값일 때만 최종 출력이 1이 되도록 설계되어 있으며, 최종 출력이 0 또는 1이 될 수 있으며, 최종 출력이 0이면 해당 레시피를 제안할 수 없지만, 최종 출력이 1이면 해당 레시피를 제안할 수 있는 것입니다.

3.2 새로운 레시피 생성을 위한 양방향

LSTM 기반 변형 자동 인코더 제안

변형 자동 인코더(VAE)는 복잡한 분포의 비지도 학습을 위한 가장 인기 있는 접근 방식 중 하나로 부상했습니다. VAE는 표준 함수 근사화기(신경망)를 기반으로 구축된다는 점에서 매력적입니다. VAE는 입력을 재구성하고, 입력을 잠재 변수로 인코딩하고, 잠재 변수에서 데이터를 생성하는 데 사용됩니다 [37][38]. GAN은 주로 이미지 재구성에 사용되는 일반

$$G = a * b^f * c^f$$

(12)

모델로도 사용됩니다. 여기서는 레시피를 생성하기 위해 양방향 LSTM 기반 VAE를 사용하겠습니다. 레시피의 모든 재료는 레시피의 이전 재료와 다음 재료에 따라 달라지기 때문에 여기서는 양방향 LSTM을 생성 모델로 사용합니다. 레시피의 맛은 요리에 사용되는 재료의 비선형적 조합에 따라 직접적으로 좌우되기 때문에 양방향 LSTM은 재료 간의 관계를 가능하게 하며, 이를 통해 모델은 사용자에게 더 적합한 요리를 예측할 수 있습니다. 그림 2는 기존 레시피에서 새로운 레시피를 생성하는 데 사용한 양방향 LSTM 기반 VAE의 아키텍처를 보여줍니다.

그림 1에 표시된 양방향 LSTM 기반 VAE에는 그림 1에 표시된 양방향 LSTM 기반 신경망 앙상블이 제안하는 추천 레시피인 그 사람에게 적합한 레시피의 데이터가 공급됩니다. 만약 이 모델에 사람에게 건강하지 않은 레시피와 사람이 좋아하지 않는 레시피의 데이터를 입력하면, 맛을 고려해서 생성 모델은 사람에게 건강하고 맛이 없는 레시피를 생성하게 됩니다. 그림 1과 2의 신경망은 모델의 용도에 따라 사람 그룹(데이터 세트의 출력은 사람 그룹이 제공한 출력의 평균) 또는 특정 사람으로부터 수집한 데이터로 훈련할 수 있습니다. 전처리는 데이터를 모델에 입력하기 전에 그림 1 및

2에 대한 자세한 내용은 다음 섹션에서 설명합니다.

방정식 (13)은 'z'의 샘플링 연산을 구현하는 데 사용되는 방정식입니다(샘플링에 사용되는 방정식)-.

$$z = \mu(x) + \sigma(x)^{\frac{1}{2}} * \epsilon \quad (13)$$

위의 방정식에서 z는 잠재 변수, $\mu(x)$ 및 $\sigma(x)$ 는 가우스 파라미터[39], $\epsilon \sim N(0,1)$ 입니다.

VAE의 재구성 손실은 식 (14)에, VAE의 KL 손실은 식 (15)에, 사용된 VAE의 완전 손실은 식 (16)에 나와 있습니다.

$$L_{\text{recon}} = \sum_k y_i * \log(\hat{y}_i) + 1 - y_i * \log(1 - \hat{y}_i) \quad (14)$$

$$L_{\text{KL}} = \frac{1}{2} \sum_k \exp(\sigma(x)) + \mu^2(x) - 1 - \sigma(x) \quad (15)$$

$$L_{\text{final}} = L_{\text{recon}} + L_{\text{KL}} \quad (16)$$

가중치 업데이트에 사용된 최적화 함수는 식 (11)과 같이 'Adam'을 사용했습니다. 모든 레이어에서 'RELU' 활성화 함수를 사용했지만, 마지막 레이어에서는 '시그모이드' 활성화 함수를 사용했습니다. 양방향 LSTM 기반 VAE에서 0에서 1 사이의 출력 값을 얻습니다. 출력 값에 기존 레시피 재료의 양을 두 배로 곱한 후 VAE에 입력으로 주어지면 새로운 레시피를 얻을 수 있습니다.

4 데이터 및 데이터 전처리

4.1 데이터 세트

데이터셋은 수집된 관찰을 수치로 정의한 데이터 모음입니다. 다양한 요리 웹사이트[40-43]에서 맛(호불호), 산도, 칼로리 함량을 예측하기 위한 데이터와 다양한 레스토랑에서 다양한 사람들의 평점을 수집했습니다. 또한 당뇨병, 소화성 궤양, 고혈압 환자를 위한 레시피의 식용 가능 여부를 분류하기 위해 데이터를 수집했습니다. 레시피는 38가지 재료에

표 1 재료 이름

성분 번호	성분	측정/으로 표 시됨
1	주성분 이름	이름
2	주요 성분	그램
3	양파	컵
4	생강 마늘	스푼
5	그린 칠리	컵
6	커드	컵
7	캐슈넛	컵
8	유고형분	그램
9	풍미 잎	카운트
10	저장용	캔
11	카다몬	스푼
12	메이스	스푼
13	캐러웨이	스푼
14	강황	스푼

매핑됩니다. 재료는 인도 요리 중심(양파, 생강 마늘, 풋고추, 두부, 캐슈넛, 우유 고형분, 향료 잎, 정향, 시나몬 카다몬, 메이스, 캐러웨이, 강황, 레드 칠리, 고수, 가람 마살라, 크림, 물, 푸디나, 푸디나, 가람 마살라, 푸디나, 버터기름, 소금, 라임, 옥수수 가루, 기름, 양파, 간장, 토마토, 토마토 소스, 식초, 커민, 코코넛, 채팅 마살라, 설탕, 레몬, 버터, 메티, 타마린드, 후추) 이러한 재료는 레시피 웹사이트에서 선택됩니다 [40-43]. 데이터 세트의 특징은 표 1에 나와 있습니다. 입력 특징 열과 출력 열이 있는 데이터 세트, 지도

16	고춧가루	스푼
17	고수	스푼
18	가람 마살라	스푼
19	크림	스푼
20	물	컵
21	푸디나	컵
22	Ghee	스푼
23	소금	숟가락
24	시간	분
25	옥수수 가루	컵
26	기름	스푼
27	파	숟가락
28	간장 소스	스푼
29	토마토	컵
30	식초	스푼
31	커민	스푼
32	코코넛	컵
33	채팅 마살라	Spoons
34	설탕	스푼
35	레몬	스푼
36	버터	숟가락
37	Methi	컵
38	타마린드	스푼
39	후추	숟가락

를 (샘플 수, 42)의 모양으로 입력 특징 열이 39개, 출력 열이 3개(맛, 산성 레시피, 고칼로리 레시피)인 데이터셋으로 변환합니다. 사용된 신경망의 입력 층은 44개의 입력 뉴런을 가지며, 입력 특징만 있는 데이터 세트는 (샘플 수, 39)의 모양을 가지며, 다음과 같은 데이터 세트가 됩니다.

모양(샘플 수, 44개)을 데이터 전처리 후 생성합니다. 그런 다음 2D 데이터를 3D 데이터로 재형성하여 모델에 입력합니다. 그림 2에 표시된 모델에서 데이터 세트는 모양(샘플 수, 39개)을 그대로 유지한 채 2D에서 3D로 변환됩니다. 데이터 전처리에 대해서는 4.2에서 설명합니다.

4.2 데이터 사전 처리

데이터 전처리는 신경망의 성능을 일반화하기 위한 중요한 프로세스입니다. 노이즈를 제거하고 데이터 세트의 결측값을 처리합니다[44]. 그림 1에 표시된 모델에 데이터를 입력하기 위한 전처리를 위해, 우리는 스킵 학습[6]의 라벨 인코더와 원핫 인코더를 사용하여 데이터를 전처리한 후 첫 번째 열을 제거하여 더미 변수 트랩을 제거했습니다. 데이터 세트에 6가지 주성분이 있으므로 주성분 열에 라벨 인코더를 사용하면 주성분 열에 6가지 주성분을 나타내는 숫자 1부터 6까지가 생깁니다. 이제 데이터에 원핫 인코더를 사용하여 카테고리 데이터를 보다 표현력 있게 표현할 수 있도록 하면 라벨 인코더를 통해 숫자(1~6)로 변환된 6개의 서로 다른 주성분을 나타내는 6개의 서로 다른 열이 생성됩니다. 이 두 단계 후에 더미 변수 함정[45]을 피하기 위해 첫 번째 열을 제거한 다음, (샘플 수, 44)의 모양에 매핑된 각 입력을 전처리한 후 신경망에 공급하기 전에 scikit 학습 라이브러리의 표준 스칼라를 사용하여 데이터의 스케일을 조정합니다. 그런 다음 2D 데이터를 (샘플 수, 44, 1)의 모양을 가진 3D 데이터로 재구성하여 그림 1에 표시된 모델에 공급합니다. 그림 2에 표시된 모델에 공급하기 위해 데이터를 전처리하기 위해 주성분 열에 라벨 인코더를 사용했으며 다음과 같은 결과를 얻었습니다.

주성분 열에 숫자 1~6을 입력하면 데이터 세트는 모양(샘플 수, 39)을 유지합니다. 라벨 인코더를 사용한 후 2D 데이터를 모양(샘플 수, 39, 1)이 있는 3D 데이터로 재형성하여 모델에 입력합니다. '주성분 1', '주성분 2', '주성분 3', '주성분 4',

'주성분 5'와 '주성분 6'은 각각 '1', '2', '3', '4', '5', '6'으로 인코딩된 라벨입니다.

5 결과 및 토론

5.1 분류 결과

3000개의 레시피(샘플 수)로 모델을 훈련하고 테스트했으며, 20개의 알려지지 않은 레시피를 수집하여 알려지지 않은 레시피에 대한 모델의 성능을 테스트했습니다. 분류기 역할을 하는 양방향 LSTM-RNN 학습자의 성능을 평가하기 위해 혼동 행렬을 플로팅하고 정밀도, 리콜, F_1 -score, 테스트 음성률, 오답률 및 정확도와 같은 성능 파라미터를 계산했습니다. 표 2는 실제 좋아요/싫어요 레시피와 예측된 좋아요/싫어요 레시피의 혼동 행렬을 보여줍니다. 표 3은 실제 산성 또는 비산성 레시피의 혼동 행렬과 예측된 산성 또는 비산성 레시피의 혼동 행렬을 보여줍니다. 표 4는 실제 고칼로리 또는 저칼로리 레시피와 예측된 고칼로리 및 저칼로리 레시피의 혼동 매트릭스를 보여줍니다. 표 5는 양방향 LSTM-RNN 학습자의 성능 파라미터를 보여줍니다. 레시피의 맛, 산도, 칼로리 함량을 예측하는 다른 기존 모델은 없기 때문에 저희 모델만의 결과를 도표로 표시했습니다.

양방향 LSTM 기반 RNN을 대신하여 KNN [46], SVM [47], 표준 신경망 [48], LSTM [49]([12-17]의 최신 모델)과의 성능 비교는 각각 표 6, 7, 8, 9에 나와 있습니다.

표 3 레시피를 산성 및 비산성(염기성)으로 분류할 때의 혼동 매트릭스

	양성 예측 (좋아요)	예측 부정적(싫어요)
실제 긍정(좋아요)	626 (TP)	72 (FN)
실제 부정(싫어요)	28 (FP)	74 (TN)

표 2 레서피를 중요요와 싫어요로 분류할 때의 혼동 매트릭스(위향에 따른 이분법적 분류)

	예측 양성(산성)	예측됨 예측됨 음수(비산성)
실제 양성(산성)	187 (TP)	56 (FN)
실제 네거티브(비산성)	32 (FP)	525 (TN)

표 4 고칼로리 레서피와 중간 또는 저칼로리 레서피로 분류할 때의 혼동 매트릭스

	예상 포지티브(고 칼로리)	예상 음성(중등도 및 저칼로리)
실제 양성(고칼로리)	371 (TP)	38 (FN)
실제 네거티브(적당히 먹 고 저칼로리)	63 (FP)	328 (TN)

표 5 성능 매개 변수
양방향 LSTM-RNN 학습자

S. 아니 요	성능 매개변수	양방향 LSTM-RNN 학습자 1	양방향 LSTM-RNN 학습자 2	양방향 LSTM-RNN 학습자 3
1	리콜	0.896	0.899	0.896
2	정밀도	0.957	0.736	0.864
3	F ₁ -score	0.925	0.809	0.879
4	트루 네거티브 비율	0.725	0.942	0.838
5	오탐률	0.274	0.057	0.161
6	정확도	0.875	0.890	0.873

표 6 KNN 학습자의 성능 매개변
수

S. 아니요	성능 매개변수	KNN 학습자 1	KNN 학습자 2	KNN 학습자 3
1	리콜	0.855	0.802	0.829
2	정밀도	0.914	0.684	0.792
3	F ₁ -score	0.884	0.739	0.810
4	트루 네거티브 비율	0.451	0.838	0.772
5	오탐률	0.549	0.162	0.228
6	정확도	0.804	0.828	0.801

표 7 SVM 학습자의 성능 매개변
수

S. 아니요	성능 매개변수	SVM 학습자 1	SVM 학습자 2	SVM 학습자 3
1	리콜	0.867	0.848	0.792
2	정밀도	0.919	0.684	0.862
3	F ₁ -score	0.892	0.757	0.825
4	트루 네거티브 비율	0.480	0.829	0.867
5	오탐률	0.520	0.171	0.133
6	정확도	0.818	0.835	0.829

표 8 표준 신경망 학습기의 성
능 매개변수

S. 아니 요	성능 매개변수	표준 신경망 학습자 1	표준 신경망 학습자 2	표준 신경망 학습 자 3
1	리콜	0.864	0.856	0.773
2	정밀도	0.942	0.693	0.895
3	F ₁ -score	0.901	0.766	0.829
4	트루 네거티브 비율	0.637	0.835	0.905
5	오탐률	0.363	0.165	0.095
6	정확도	0.835	0.841	0.838

표 9 LSTM 학습기의 성능 파
라미터

S. 아니요	성능 매개변수	LSTM 학습자 1	LSTM 학습자 2	LSTM 학습자 3
1	리콜	0.883	0.852	0.809
2	정밀도	0.945	0.772	0.887
3	F ₁ -score	0.913	0.810	0.847
4	트루 네거티브 비율	0.647	0.890	0.893
5	오탐률	0.353	0.110	0.107
6	정확도	0.853	0.879	0.850

표 10 분류 중 양방향 LSTM-RNN 학습자가 예측한 실제 값과 예측값

레시피 번호	실제 좋아요 와 싫어요	실제 산성 레시 피	실제 고칼로 리 레시피	좋아요 및 싫어요 예측(값이 0.5를 초과하면 1로 간주, 그 렇지 않으면 0으로 간 주)	산성 레시피 예측(값이 0.5를 초과하면 1로 간주, 그 외에는 0으로 간주)	고칼로리 예측(값이 0.5를 초과하면 0으로 간주)
01	1	1	0	0.979	0.925	0.340
02	1	1	1	0.730	0.533	0.570
03	1	1	0	0.681	0.544	0.343
04	1	0	0	0.411	0.405	0.292
05	0	1	0	0.286	0.606	0.229
06	0	1	0	0.361	0.705	0.040
07	0	0	0	0.383	0.419	0.254
08	1	1	0	0.735	0.753	0.349
09	0	0	0	0.361	0.353	0.395
10	0	0	0	0.472	0.405	0.179
11	1	1	1	0.687	0.824	0.592
12	1	1	0	0.667	0.765	0.468
13	0	1	0	0.346	0.881	0.286
14	0	0	0	0.467	0.499	0.212
15	0	0	0	0.223	0.305	0.130
16	1	0	0	0.532	0.287	0.205
17	1	0	0	0.598	0.374	0.180
18	1	1	0	0.985	0.883	0.317
19	0	1	0	0.214	0.886	0.185
20	1	1	0	0.592	0.688	0.293

20개의 알려지지 않은 레시피에 대해 분류 모델을 테스트했습니다. 표 10은 실제 좋아요와 싫어요, 실제 산성 레시피, 실제 고칼로리 레시피와 함께 예측된 좋아요와 싫어요, 예측된 산성 레시피, 예측된 고칼로리 레시피를 보여줍니다. 예측 값 은 양 방 향 L S T M - R N N 학 습 자 의 출력 값 으 로 , 양 방 향 L S T M - R N N 학 습 자 의 출 력 이 0 . 5보다 작으면 0으로 간주하고 양방향 LSTM-RNN 학습자의 출력이 0.5보다 크면 1로 간주합니다.

양방향 LSTM-RNN 학습자 1,2,3이 값을 사전 입력한 후, 그림 1의 논리 회로로 이동하기 전에 이진 입력 컨버터 블록에서 자동으로 0초와 1초로 변환됩니다. 20개의 미지의 레시피에 대한 모델의 최종 출력 또는 제안은 표에 나와 있습니다. 11.

5.2.1 맛 평가 예측

분류에서 얻은 출력은 이진 출력이었으며, 맛 등급과 칼로리 함량에 대해서는 양방향 LSTM-RNN 학습자 1과 3을 훈련시켜 맛 등급과 칼로리 함량을 미리 받아쓰도록 해야 합니다. 이를 위해

5.2 맛 등급 예측 및 칼로리 함량 예측

과 칼로리 함량을 얻었으며, 출력이 이진 입력 1 블록과 이진 입력 3 블록을 통과한 후 자동으로 0초와 1초로 변환됩니다. 그림 3은 실제 맛 등급을 보여줍니다. 그림 4는 'MSE' 또는 '평균 제곱 오차'로 예측된 맛 등급을 보여줍니다. 그림 5는 'MAE' 또는 '평균 절대 오차'로 예측된 맛 등급을 보여줍니다. 그림 6은 사용자 지정 손실 함수를 사용한 예측된 맛 등급을 보여줍니다.

5.2.2 칼로리 예측

레시피, 산성 레시피, 고칼로리 레시피 분류에 사용된 것과 동일한 20개의 알려지지 않은 레시피로 칼로리 값을 예측하기 위해 양방향 LSTM-RNN 학습자 3을 테스트했습니다. 그림 7은 20개 레시피의 실제 칼로리 값을 보여줍니다. 그림 8은 20개 레시피의 예측 칼로리 함량을 보여 주며, 20개 레시피의 실제 칼로리 함량을 보여주는 그림 7과 비슷하고 정확해 보입니다.

5.3 양방향 LSTM 기반 VAE를 사용한 레시피 생성

특정 사용자가 좋아하는 레시피로 변형 자동 인코더를 학습시켜 다음을 생성했습니다.

표 11 이진 변환 및 논리 회로 통과 후 제안 사항

레시피 번호	좋아 요	산성 특성	칼로리 함량	제안(제한이 없는 사 람)	제안(산도에 제한이 있는 사람)	제안(칼로리 제한이 있는 분)	제안(산도와 칼로리 제한 이 모두 있는 분)
01	1	1	0	1	0	1	0
02	1	1	1	1	0	0	0
03	1	1	0	1	0	1	0
04	0	0	0	0	0	0	0
05	0	1	0	0	0	0	0
06	0	1	0	0	0	0	0
07	0	0	0	0	0	0	0
08	1	1	0	1	0	1	0
09	0	0	0	0	0	0	0
10	0	0	0	0	0	0	0
11	1	1	1	1	0	0	0
12	1	1	0	1	0	1	0
13	0	1	0	0	0	0	0
14	0	0	0	0	0	0	0
15	0	0	0	0	0	0	0
16	1	0	0	1	1	1	1
17	1	0	0	0	1	1	1
18	1	1	0	1	0	1	0
19	0	1	0	0	0	0	0
20	1	1	0	1	0	1	0




그림 4 'MSE' 또는 '평균 제곱 오차'가 있는 예측된 맛 등급




그림 5 'MAE' 또는 '평균 절대 오차'가 포함된 예측된 맛 등급

개인의 취향에 따라 그 사람을 위한 레시피를 생성하거나, 여러 사람의 취향에 따라 그룹을 위한 레시피를 생성할 수 있습니다. 기존 파니 레시피 5가지에서 새로운 파니 레시피 5가지를 생성했습니다. 그림 9는 기존 레시피의 재료를, 그림 10은 새로운 레시피를 만들기 위해 생성된 재료를 보여줍니다.

다. 새로운 레시피 1, 새로운 레시피 2, 새로운 레시피 3, 새로운 레시피 4, 새로운 레시피 5는 기존 레시피 1, 기존 레시피 2, 기존 레시피 3, 기존 레시피 4에서 생성된 새로운 레시피입니다.

레시피 3, 기존 레시피 4 및 기존 레시피 5를 각각 사용합니다. 이 모든 레시피에서 주재료인 파니의 무게는 240~250g이며, 아래 그래프를 그릴 때 더 나은 그래프를 위해 250g인 주재료의 무게를 1로 조정했습니다. 또한 더 나은 그래프를 위해 시간을 분 단위로 표시하지 않고 시간 단위로 표시했습니다.




그림 6 사용자 지정 손실 기능을 사용한 예측된 맛 등급

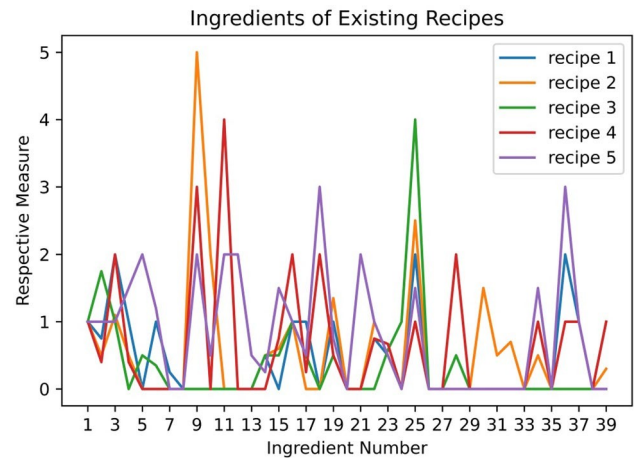


그림 9 기존 레시피의 재료




그림 7 20가지 레시피의 실제 칼로리




그림 10 생성된 새로운 레시피의 재료


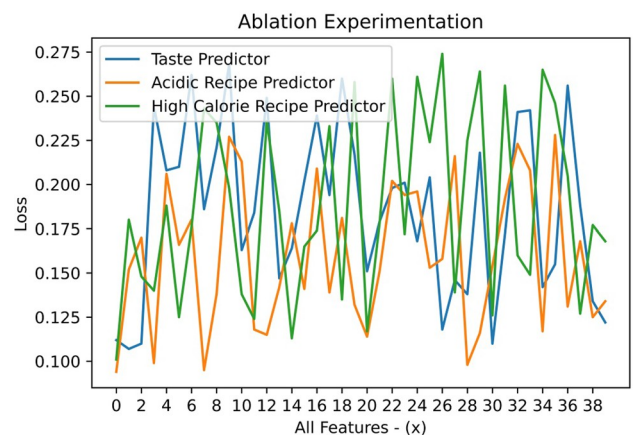


그림 8 20가지 레시피의 예상 칼로리 함량



5.4 절제 실험

제거 실험을 통해 데이터 세트의 입력 특징을 평가했습니다. 40가지의 서로 다른 데이터 세트 구성을 테스트했습니다. 데이터 세트의 첫 번째 구성은 모든 입력 기능으로 구성되었습니다. 다음 39개의 구성은 각각 하나의 입력 특징이 부족합니다. 그림 11은 수행한 제거 실험의 결과를 보여줍니다. 이 테스트를 수행하기 위해 이진 교차 엔트로피 손실 함수를 사용했습니다. 표 11에서는 성분(입력 특징)을 나타내는 숫자를 사용했는데, 이는 표 1에 표시된 성분의 일련 번호입니다. 1에 표시된 성분의 일련번호를 사용하여 각 입력 특징을 나타냈습니다. 입력 기능이 각각 부족한 39개의 구성은 '모든 기능-X'로 표시되며, 여기서 'X'는 해당 구성이 부족해야 하는 입력 기능의 일련 번호입니다. 'X'는 $X = \{1, 2, 3, \dots, 39\}$ 로 주어지며 '모든 기능'은 모든 입력 기능이 포함된 데이터 세트 구성입니다. 결과

은 데이터 세트에서 각 기능의 중요도를 보여줍니다.

위 그림에서 입력 구성이 다른 경우의 손실을 확인할 수 있습니다. 손실 값이 가장 높은 구성은 가장 중요한 입력 기능이 누락된 것이고, 손실 값이 가장 낮은 구성은 가장 적은 가져오기 입력 기능이 누락된 것입니다. 손실값을 내림차순으로 정렬하면 누락된 각각의 입력 기능과 함께 가장 중요한 입력 기능부터 가장 중요하지 않은 입력 기능까지 입력 기능의 순서를 얻을 수 있습니다. 모든 재료가 요리의 맛과 기타 특성에 영향을 미치기 때문에 입력 특징을 선택할 때 특징 필터링 기법을 사용하지 않았습니다.

5.5 토론

이진 분류 중에 훈련 및 검증 데이터를 사용하여 양방향 LSTM-RNN 학습자의 정확도를 플롯했습니다. 그림 12는 정확도를 보여줍니다.

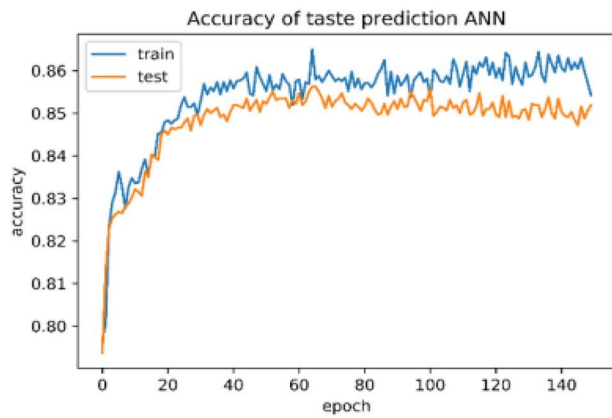
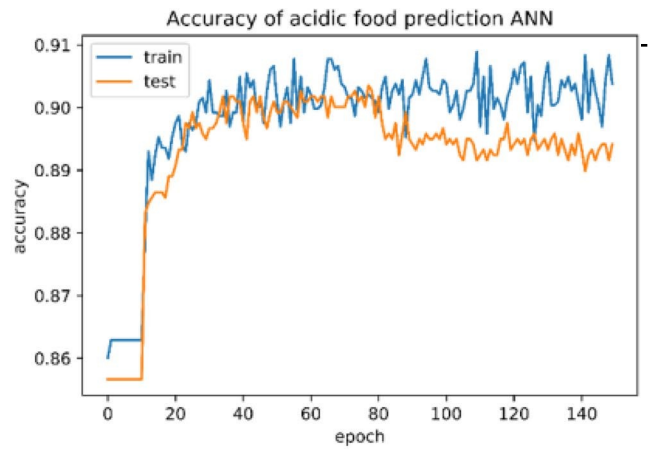
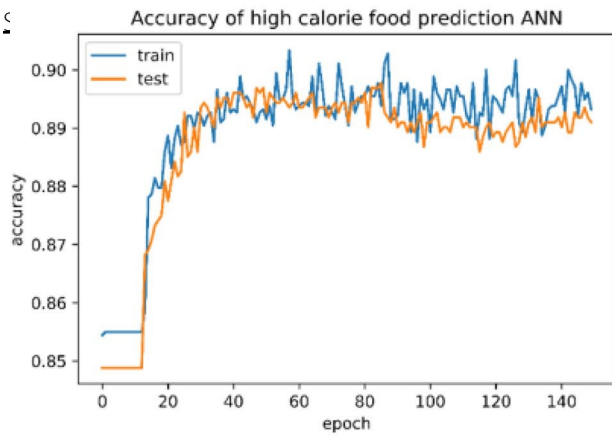


그림 12 맛에 따라 레시피를 분류하는 양방향 LSTM-RNN 학습자 1의 정확도(왼쪽), 산도에 따라 레시피를 분류하는 양방향 LSTM-RNN 학습자 2의 정확도(가운데).

칼로리 함량을 기반으로 레시피를 분류하는 동안 양방향 LSTM-RNN 학습자 3의 정확도(오른쪽)

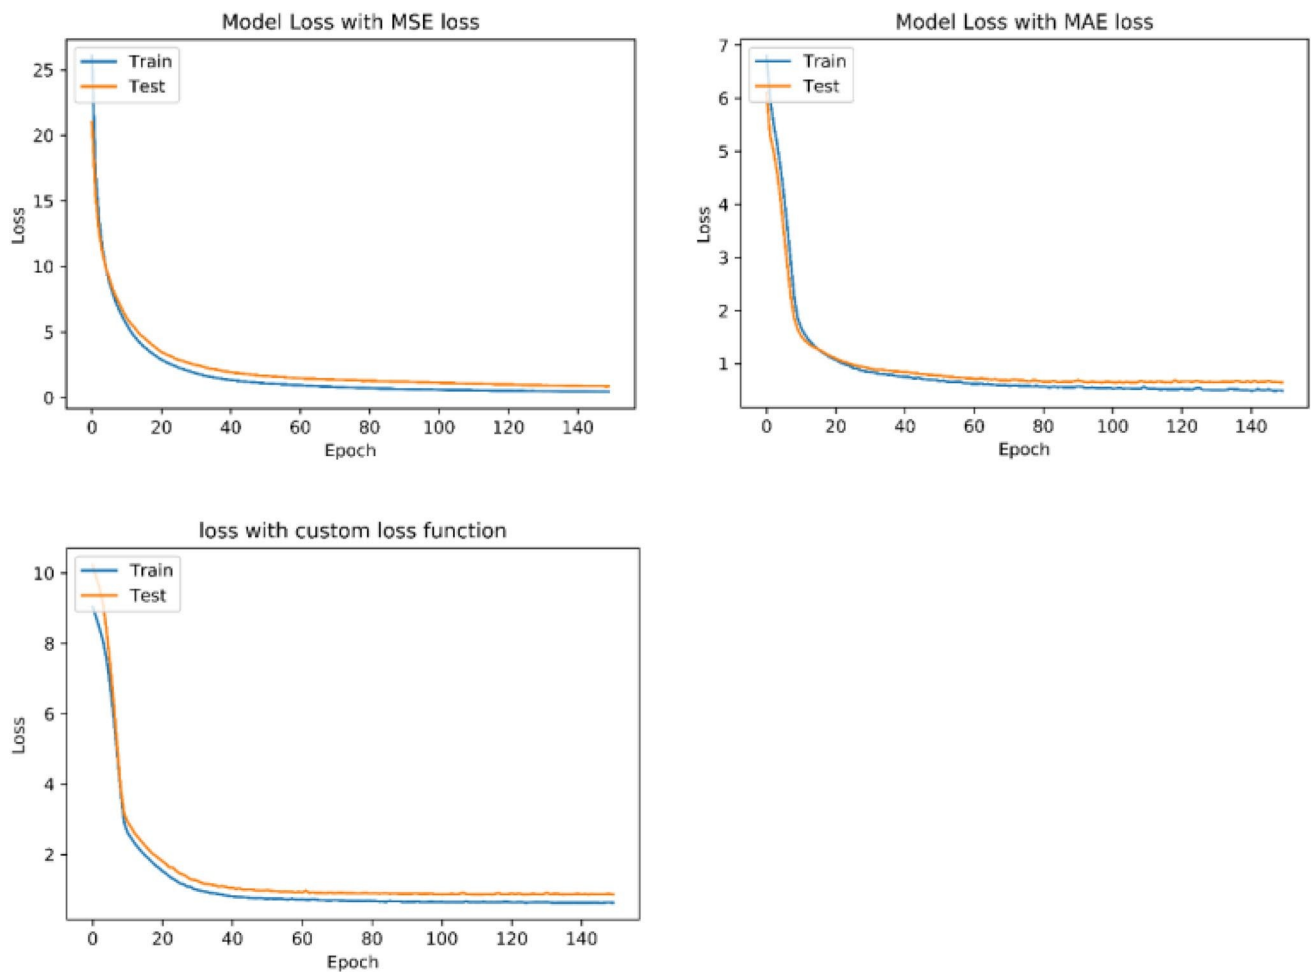


그림 13 'MSE'(왼쪽), 'MAE'(가운데) 및 사용자 지정 손실 함수(오른쪽)로 맛 등급을 예측하는 동안의 양방향 LSTM-RNN 학습자 1의 손실(왼쪽)


의 양방향 LSTM-RNN 학습자를 대상으로 맛이나 호불호, 산도 및 칼로리 함량에 따라 레시피를 분류합니다.

'MAE' 또는 '남성 제곱 오차', 'MAE' 또는 '평균 절대 오차'와 이 문제에 대해 설계한 사용자 지정 손실 함수를 사용하여 훈련 및 검증 데이터로 맛 등급을 예측하는 동안 양방향 LSTM-RNN 학습자 1의 손실 그래프를 플롯했습니다. 그림 13은 다양한 손실 함수를 적용한 양방향 LSTM-RNN 학습자 1의 정확도를 보여줍니다.

레시피의 칼로리 함량을 예측하는 동안 양방향 LSTM-RNN 학습자 3의 손실도 플롯했습니다. 그림 14는 훈련 및 검증 데이터에 대한 양방향 LSTM-RNN 학습자 3의 손실을 보여줍니다.

레시피를 생성하기 위해 VAE를 훈련하는 동안 계산된 훈련 손실과 검증 손실을 도표로 표시했습니다. 그림 15는 다양한 VAE 모델의 훈련 손실과 검증 손실을 플롯한 것입니다.

그림 14 칼로리 함량을 예측 하는 동안 양방향 LSTM-RNN
학습자 3의 손실






그림 15 표준 신경망 VAE 성능(왼쪽 상단), LSTM-VAE 성능(오른쪽 상단), BI-LSTM VAE 성능(하단)

레시피 생성에 대한 교육을 받으면서 다양한 VAE 모델의 성능을 테스트할 수 있습니다.

6 결론

본 논문에서는 맛, 산도, 칼로리를 기준으로 레시피를 분류할 수 있는 양상블 신경망 아키텍처를 제안하고, 기존의 표준 레시피에서 새로운 레시피를 생성하는 생성 모델로 사용되는 변형 자동 인코더를 제안합니다. 우리가 제안한 모델의 결과는 맛, 산도, 칼로리를 기반으로 레시피를 분류하는 데 있어 높은 정확도를 제공합니다. 분류 결과를 평가하기 위해 정확도, 회상도, F-점수, 오탐률, 정탐률, 미지의 레시피 20개를 대상으로 한 모델의 성능 등 다양한 성능 평가 파라미터가 포함되었습니다. 양방향 LSTM-RNN 학습자 1과 양방향 LSTM-RNN 학습자 3이 각각 맛 등급과 칼로리 함량을 예측하는 회귀 모델로 작동하는 동안 모델의 작동을 확인하기 위해 20개의 미지의 레시피에 대한 맛 등급 예측과 칼로리 함량 예측에서 얻은 결과를 표시했습니다. 변형 자동 인코더 모델의 작동을 확인하기 위해 기존 레시피 2개에서 새로운 레시피 2개를 생성했습니다. 맛, 산도, 칼로리 함량을 기반으로 레시피를 제안할 수 있는 양상블 인공지능의 독창성을 고려할 때, 앞으로 더 많은 연구를 통해 더 나은 모델을 만들 수 있을 것으로 기대합니다.

감사의 말 이 연구는 인도 텔랑가나주 차이타나 바라티 공과대학의 지원을 받아 수행되었습니다.

선언

이해 상충 저자(들)는 경쟁 관계에 있는 이해관계가 없음을 선언합니다.

오픈 액세스 이 문서는 사용, 공유를 허용하는 크리에이티브 커먼즈 저작자 표시 4.0 국제 라이선스에 따라 라이선스가 부여됩니다,

브 커먼즈 라이선스 링크를 제공하며, 변경된 경우 이를 명시하는 한 모든 매체 또는 형식으로 각색, 배포 및 재생산할 수 있습니다. 이 기사의 이미지 또는 기타 제3자 자료는 자료의 크레딧 라인에 달리 명시되지 않는 한 해당 기사의 크리에이티브 커먼즈 라이선스에 포함되어 있습니다. 자료가 기사의 크리에이티브 커먼즈 라이선스에 포함되지 않았고 사용하기에 자료가 법적 규정에 의해 허용되지 않거나 허용된 사용 범위를 초과하는 경우 저작권 소유자로부터 직접 허가를 받아야 합니다. 이 라이선스의 사본을 보려면 <http://creativecommons.org/licenses/by/4.0/>를 방문하세요.

참조

1. Prasad NN, Siddalingaswamy M, Parameswariah PM, Radhakrishna K, Rao RV, Viswanathan KR, Santhanam K (2000) 일부 가공 된 전통 및 인기있는 인도 요리의 프록시 메이트 및 미네랄 성분. 식품 화학 68(1):87-94
2. Bhatia SJ, NageshwarReddy D, Ghoshal UC, Jayanthi V, Abraham P, Choudhuri G, Broor SL 외 (2011) 인도 인 구에서 위식도 역류의 역학 및 증상 프로파일 : 인도 소화기 학회 태스크 포스 보고서. Indian J Gastroenterol 30(3):118
3. 살바도르, A, 드로즈잘 M, 지로-이-니에토 X, 로메로 A (2019) 역 요리: 음식 이미지에서 레시피 생성. In: 컴퓨터 비전 및 패턴 인식에 관한 IEEE 컨퍼런스 프로시딩 , 10453-10462페이지
4. 살바도르 A, 하인즈 N, 아이타르 Y, 마린 J, 오픈리 F, 웨버 I, 토랄바 A (2017) 요리 레시피 및 음식 이미지를 위한 크로스 모달 임베딩 학습. In: IEEE 컨퍼런스 논문집 컴퓨터 비전 및 패턴 인식, 3020-3028쪽
5. Cruz, ELA (2015) 맥주 맛 품질 예측을 위한 인공 신경망 구현
6. Géron, A (2019) 실습용 머신 러닝: 개념, 도구 및 기법 지능형 시스템 구축. 오라일리 미디어, 2019
7. 간디 N, 페트카르 O, 암스트롱 LJ (2016) 인공 신경망을 이용한 쌀 작물 수확량 사전 예측. 2016 IEEE 농업 및 농촌 개발을위한 ICT의 기술적 혁신- 멘토 (TIAR), 105-110 쪽. IEEE
8. Jovanović RŽ, Sretenović AA, Živković BD (2015) 난방 에너지 예측을위한 다양한 신경망의 앙상블 소비. 에너지 빌드 94(2015):189-199
9. 이 H, 홍 S, 김 E (2009) 확률적 융합을 이용한 신경망 앙

10. Chokr M, Elbassuoni S (2017) 음식 이미지에서 칼로리 예측. In: 인공 지능 (AAAI'17)의 제 31 회 AAAI 컨퍼런스 프로시저. AAAI Press, 4664-4669페이지
11. Trattner C, Elswailer D (2017) 식품 추천 시스템: 중요한 기여, 과제 및 향후 연구 방향." arXiv 사전 인쇄물 arXiv:1711.02760.
12. Elswailer D, Hors-Fraile S, Ludwig B, Said A, Schäfer H, Trattner C, Orkamaan H, Valdez AC (2017) 건강 추천 시스템에 대한 두 번째 워크숍: (healthrecsys 2017). In: 제11회 추천자 시스템에 관한 ACM 컨퍼런스, RECSYS 2017, 이탈리아 코모, 2017년 8월 27-31 일 (374-375페이지)
13. Elswailer D, Trattner C, Harvey M (2017) 더 건강한 레시피 추천을 위해 음식 선택 편향 활용. In: 정보 검색 연구 및 개발에 관한 제 40회 국제 ACM SIGIR 컨퍼런스 논문집(575-584쪽).
14. 엘스바일러 D, 하비 M, 루드비히 B 사이드 A (2015) 식품 추천에 '건강'을 도입합니다. In: Dmrs (33-36쪽)
15. 하비 M, 루드비히 B, 엘스바일러 D (2013) 당신은 당신이 먹는 것입니다: 평점 예측을 위한 사용자 취향 학습. In: 제20회 문자열 처리 및 정보 검색에 관한 국제 심포지엄 논문집 8214권(153-164쪽).
16. Teng C-Y, Lin Y-R, Adamic LA (2012) 재료 네트워크를 사용한 레시피 추천. In: 제4회 연례 ACM 웹 과학 컨퍼런스(298-307쪽).
17. Freyne J, Berkovsky S (2010) 지능형 음식 계획: 개인화 된 레시피 추천. In: 제15회 지능형 사용자 인터페이스 국제 컨퍼런스 자료집 (321-324쪽)
18. Pouladzadeh P, Kuhad P, Peddi SVB, Yassine A, Shirmohammadi S (2016) 딥 러닝 신경을 사용한 음식 칼로리 측정 네트워크. 1-6. <https://doi.org/10.1109/I2MTC.2016.7520547>.
19. Zhou L, Zhang C, Liu F, Qiu Z, He Y (2019) 식품에 대한 딥 러닝의 적용 : 검토. Compr Rev Food Sci Food Saf 18:1793-1811
20. 야오 Y, 정 H (2016) 중국어 단어 세분화를위한 양방향 LSTM 순환 신경망 작업. In: 신경 정보 처리에 관한 국제 컨퍼런스, 345-353쪽. Springer, Cham
21. 송 X, 리우 Y, 쉬 L, 왕 J, 장 J, 왕 J, 장 L, 청 Z (2020) 장단기 기억 (LSTM) 신경망 모델에 기반한 시계열 유정 성능 예측. J Petrol Sci Eng 186:106682
22. Xie G, Shangguan A, Fei R, Ji W, Ma W, Hei X (2020) CNN-LSTM 순차 모델에 기반한 모션 트래젝토리 예측. Sci 중국 정보과학 63(11):1-21
23. Tasci E (2020) 음식 이미지 인식을위한 미세 조정 된 컨볼 루션 신경망의 투표 조합 기반 앙상블 . 멀티메드 도구 응용 79(41):30397-30418
24. Shen S, Sadoughi M, Li M, Wang Z, Chao Hu (2020) 리튬 이온 배터리의 용량 추정을위한 앙상블 학습 및 전이 학습을 통한 심층 컨볼 루션 신경망. Appl 에너지 260:114296
25. Bahad P, Saxena P, Kamal R (2019) 양방향 LSTM 순환 신경망을 사용한 가짜 뉴스 탐지. Proc Comput Sci 165:74-82
26. Dai X, Yin H, Jha NK (2019) 작고 빠르며 정확한 LSTM의 성장과 가지치기. IEEE 트랜스컴퓨팅 69(3):441-452
27. 정 J, 굴세레 C, 조 KH, 벤지오 Y (2014) 시퀀스 모드에 대한 게이트 순환 신경망의 경험적 평가 eling." arXiv preprint arXiv:1412.3555.
28. Ramos D, Franco-Pedroso J, Lozano-Diez A, Gonzalez-Rodriguez J (2018) 확률 이진 분류기를위한 교차 엔트로피 분해. 엔트로피 20(3):208

29. 슈미트-히버 J (2017) ReLU 활성화 기능이 있는 심층 신경망을 사용한 비모수 회귀 분석." arXiv 사전 인쇄 arXiv:1708.06633
30. 에클 K, 슈미트-히버 J (2019) ReLU 활성화 함수와 선형 스플라인 유형 방법을 사용한 심층 네트워크의 비교. 신경망 110:232-242
31. Zhang H, Tsui-Wei W, Pin-Yu C, Cho-Jui H, Luca D (2018) 일반 활성화 기능을 통한 효율적인 신경망 견고성 인증. In: 신경 정보 처리 시스템의 발전-tems, pp 4939-4948
32. 빌 HD, 데무스 HB, 헤이건 MT (1996) 신경망 설계. Pws, 보스턴
33. De Myttenaere A, Golden B, Le Grand B, Rossi F (2016) 회귀 모델의 평균 절대 백분율 오류. 뉴로컴퓨팅 192(2016):38-48
34. Khair, U, Fahmi H, Al Hakim S, Rahim R (2017) 평균 절대 편차 및 평균 절대 백분율 오류를 사용한 예측 오류 계산. In: 물리학 저널: 컨퍼런스 시리즈, vol 930, 1, p 012002. IOP 출판
35. Kingma DP, Ba J (2014) Adam: 확률론적 최적화를 위한 방법 tion.
36. 시바 SG (ed) (2018) 로직 디자인 입문. CRC Press, 캠브리지
37. Wan Z, Zhang Y, He H (2017) 불균형 학습을 위한 변형 자동 인코더 기반 시네틱 데이터 생성. In: 2017 IEEE 컴퓨터 지능 심포지엄 시리즈(SSCI), 1-7쪽. IEEE
38. Semeniuta S, Severyn A, Barth E (2017) 텍스트 생성을 위한 하이브리드 컨볼루션 변형 자동 인코더. arXiv 사전 인쇄 arXiv:1702.02390
39. Ma C, Gong W, Hernández-Lobato JM, Koenigstein N, Nowozin S, Zhang C (2018) 하이브리드 추천 시스템을 위한 부분적 VAE. In: 베이지안 딥러닝에 관한 NIPS 워크샵
40. <https://www.allrecipes.com/>
41. <https://www.indianhealthyrecipes.com/recipes/veg-curry/>
42. <https://in.pinterest.com/sw-shell.html>
43. <https://www.cookwithmanali.com/category/recipes/indian-메인-코스-채식주의자-레시피/>
44. Kotsiantis SB, Kanellopoulos D, Pintelas PE (2006) 데이터 사전 처리 - 감독된 기율기를 위한 예싱. Int J Comput Sci 1(2):111-117
45. Pal M, Bharati P (2019) 더미 설명 변수가있는 회귀 모델. In: 회귀 기법의 응용, 135-153쪽, Springer, Singapore
46. Guo G, Wang H, Bell D, Bi Y, Greer K (2003) 분류에서 KNN 모델 기반 접근 방식. In: OTM 연합 국제 컨퍼런스 "의미있는 인터넷 시스템으로의 이동", pp 986-996. 스프링거, 베를린
47. Shon T, Moon J (2007) 네트워크 이상 탐지에 대한 하이브리드 머신 러닝 접근 방식. Inf Sci 177(18):3799-3821
48. Sarle, WS (1994) 신경망과 통계 모델
49. 스리바스타바 N, 만시모프 E, 살라쿠디노프 R (2015) lstrms를 사용한 비디오 표현의 비지도 학습. In: 머신 러닝 국제 컨퍼런스, 843-852페이지

발행인 주 스프링거 네이처는 출판된 지도의 저작권 주장 및 기관 소속과 관련하여 중립을 유지합니다.